

RISC-V上AI应用与实践

生成式AI应用构建

王智创

2025年3月23日

目录

01

RISC-V 简介

02

RISC-V与AI

03

RISC-V上的AI 应用与实践

04

未来展望

01 RISC-V简介



01 RISC-V简介

■ 以用为本 拥抱创新

发展历程

诞生

201

正式进入中国

201

RISC-V国际基金会成立


201

爆发期

202


发展势头迅猛的开源指令集架构

RISC-V核心特性




开源开放

免授权费
自由创新



模块化设计

支持自定义指令扩展，
例如为AI模型设计专用加速单元。



灵活定制

既能做能效比超高的边缘芯片，
也能扩展为64核高性能CPU。

全球与中国行业现状

阿里达摩院玄铁系列、进迭时空、知合科技、奕斯伟等企业已构建从IP核到工具链的全栈能力。

市场

截至2024年RISC-V芯片出货量170亿颗，预计2030年市场规模达250亿美元，年复合增长率47.9%。

生态

RISC-V国际基金会显示全球会员单位已达4000多家，国内以中科院软件所为主的科研机构 and 以达摩院为达标的企业纷纷参与生态建设

政策

作为众多指令集架构中，唯一开源开放的。为我国突破芯片半导体技术，带来了很大的机遇。政策方面提供了很多支持。

02 RISC-V与AI

精简指令集为AI而生



AI算力只能依赖于GPU吗？

AI算力主流是GPU，但是除了GPU还有其他比如TPU、NPU、GPGPU、FPGA、ASIC

除了这些得益于灵活定制+开放生态 RISC-V也是一个很好的选择

现有AI芯片技术架构分类					
技术架构种类	定制化程度	算力	价格	优点	应用场景
GPGPU	通用型	高	高	相较传统的GPU，缩减图形相关功能，具有更优的计算能效比	互联网、智慧安防、金融等通用计算领域和人工智能平台
FPGA	半定制化	高	中	可通过编程灵活配置芯片架构适应算法迭代，平均性能较高；功耗较低；开发时间较短	适用于各种具体的行业
ASIC	全定制化	高	低	通过算法固化实现极致的性能和能效、平均性强；功耗很低；体积小	当客户处于某个特殊场景，可为其设计一套专业的智能算法软件
存算一体	通用型	更高	低	高能效比；能绕过先进制程封锁；兼顾更强通用性与更高性价比	数据中心、自动驾驶等

来源：根据公开资料查询，德睿咨询整理

DeepSeek带来的机遇

DeepSeek的出现，为算力市场带来了更多可能性。DeepSeek通过MOE架构让激活参数比大幅下降，降低的算力需求可以达到近20倍，这给国产芯片带来的机会，未来所有芯片都有希望具备适配大模型能力

DeepSeek 开源了一些代码仓库，很多优化都和硬件相关



RISC-V与AI强强联合

RISC-V凭借开放性架构支持定制化扩展（如矩阵计算指令集、近存计算单元），未来可通过开源生态共建实现算法-芯片联合优化，为国产芯片提供超越CUDA生态的差异化竞争力



- 中国科学院软件所RISC-V行业生态负责人郭松柳表示，AI软件栈仍在高速演进，RISC-V作为三大主流指令集架构中最灵活、最开放的一个，无疑最适合AI时代的技术创新节奏。
- “RISC-V最符合绿色、开放、融合的要求，可以说，它就是为AI时代而生的，是AI时代的天选之子。” 中国RISC-V生态大会共同主席、奕斯伟集团董事长王东升说。

玄铁AI融合平台

曳影1520芯片：

TH1520 是首颗基于无剑600芯片设计平台研发的量产 多模态 AI 视觉 RISC-V 处理器芯片，支持全链路安全防护。

特性	说明
CPU	4核玄铁C910，最高主频1.85GHz
NPU	支持4TOPS@INT8通用NNA算力，主频1GHz
GPU	内嵌3D GPU完全兼容OpenGL ES 1.1/2.0/3.0/3.1，OpenCL 1.1/1.2/2.0，Vulkan 1.1/1.2，支持2D加速引擎，以及通用DSP加速器
存储	双通道外部存储器接口，支持LPDDR4/LPDDR4X，最高速率可达4266Mbps
Codec	支持H.265/H.264/VP9标准视频编码，最高分辨率达4K@40fps；支持H.265/H.264/VP9/AV52等多格式视频解码，最高分辨率达4K@75fps
摄像头	支持3路输入，2路ISP处理，最高1.3M像素
显示	双路DPU，支持4K@30fps和1080p@60fps显示
安全	支持TEE和REE，TEE/REE支持核数启动时可配置

玄铁AI融合平台

算法生态&应用示例：

1. 大模型应用示例

- 大语言模型 Qwen-1.8B
- 多模态大模型 Kosmos2

2. 视觉 AI 应用示例

- 视觉分割模型
- 超分算法
- 目标识别
- 手势识别

3. 语音应用示例

- ASR 识别



02 RISC-V与AI


■ 以用为本 拥抱创新

玄铁AI融合平台

多模态模型：

- 选择图片
- 对话

Kosmos2 模型仅支持英文对话。



03 生成式AI应用在RISC-V上的实践



03 生成式AI应用在RISC-V上的实践

■ 以用为本 拥抱创新

环境介绍

- 操作系统：openEuler-24.03-LTS（RISC-V）
- 运行环境：ubuntu-24.04 (docker)
- CPU：玄铁C920 * 64核
- TPU：sophgo BM1684X 14GB * 3

```
Tue Mar 11 14:18:19 2025
```

Lib Version: 0.5.1						Driver Version: 0.5.1					
card	Name	Mode	SN	TPU	boardT	chipT	TPU_P	TPU_V	ECC	CorrectN	Tpu-Util
12V_ATX	MaxP	boardP	Minclk	Maxclk	Fan	Bus-ID	Curclk	TPU_C	Memory-Usage		
0	SC7+	PCIE	HQDZW1TBCABAC0096	0	49C	49C	3.0W	731mV	OFF	N/A	0%
3648mA	75W	43W	25M	750M	N/A	001:81:00.0	750M	4.1A		78MB/14781MB	
				1	48C	50C	3.1W	730mV	OFF	N/A	0%
				001:81:00.1	Active	750M	4.3A			78MB/14781MB	
				2	44C	49C	3.1W	730mV	OFF	N/A	0%
				001:81:00.2	Active	750M	4.3A			78MB/14781MB	

Processes:				TPU	Memory
TPU-ID	PID	Process name		Usage	

03 生成式AI应用在RISC-V上的实践

■ 以用为本 拥抱创新

大语言模型

deepseek-r1-distill-qwen2-7b (riscv) ▾ +

如何证明 $\sqrt{2}$ 是无理数?

Q | deepseek-r1-distill-qwen2-7b (riscv)

已推理 持续 2 分钟 ▾

首先, 我们假设 $\sqrt{2}$ 是有理数, 即存在整数 a 和 b , 使得 $\sqrt{2} = a/b$, 并且 a 和 b 互质。两边平方得到:

$$2 = \frac{a^2}{b^2}$$

即:

$$a^2 = 2b^2$$

因为 a^2 是2的倍数, 所以 a 也是2的倍数。设 $a = 2k$, 其中 k 是一个整数。代入上式得到:

$$(2k)^2 = 2b^2$$

$$4k^2 = 2b^2$$

$$2k^2 = b^2$$

这说明 b^2 也是2的倍数, 因此 b 也是2的倍数。这样, a 和 b 都是2的倍数, 说明它们有公因数2, 这与 a 和 b 互质相矛盾。因此, 最初的假设错误, $\sqrt{2}$ 不能表示为两个整数的比, 所以 $\sqrt{2}$ 是无理数。

$\sqrt{2}$ 是无理数

模型:

... 三 deepseek-r1-distrill-qwen2-7b/deepseek-r1-distrill-qwen2-1.5b

TPU显存: 14G * 3

tokens/s:

deepseek-r1-distrill-qwen2-1.5b:
首个token 6.4s, 生成速度
14.8token/s; 显存占用1.5GB

deepseek-r1-distrill-qwen2-7b:
首个token 3.6s, 生成速度
7.7token/s; 显存占用4GB

03 生成式AI应用在RISC-V上的实践

■ 以用为本 拥抱创新

多模态应用-StableDiffusion

自然风景

自然风光 城市风光

Positive Prompt

beautiful landscape photography, golden hour, dramatic lighting, 8k uhd, professional photography

Negative Prompt

people, buildings, vehicles, text, watermark, oversaturated

推理步数

20

生成图像

图像生成成功



耗时统计	
提示词编码时间	180.52 ms
推理时间	45863.29 ms
VAE解码时间	2597.30 ms
总耗时	48641.11 ms

模型：

StableDiffusionXL/StableDiffusionV1.5

TPU显存：14G * 3

模型大小：

StableDiffusionXL：10G 左右

StableDiffusionV1.5：2G 左右

单芯图片生成耗时：

StableDiffusionXL：50s 左右
(1024*1024)

StableDiffusionV1.5：6s 左右
(512*512)

03 生成式AI应用在RISC-V上的实践

■ 以用为本 拥抱创新

算能TPU框架介绍

TPU-MLIR工具链

PyTorch模型可快速编译为RISC-V平台的bmodel格式，加速AI落地



开放源码

TPU-MLIR 工程的所有代码都已开源，向所有用户免费开放。用户在使用本工程的同时也可以参与到该工程的完善与改进工作中，共同创造出一款站在时代前沿的 AI 编译器。



入手简单

通过阅读开发手册与工程中已包含的样例，用户可以快速地了解模型转化流程与原理，从而入门该工程。并且，TPU-MLIR 基于当前主流的编译器工具库 MLIR 进行模型化设计，用户也可以透过该工程来学习 MLIR 的应用，知识点丰富，应用面广。



使用便捷

该工程目前已经提供了一套完备的工具链，用户可以直接通过现有接口快速地完成模型的转化工作，节约大量投入在适配不同网络的过程中所花费的时间成本。



多框架支持

目前 TPU-MLIR 已经支持 tflite 以及 onnx 格式，该类格式模型可以使用本工程直接进行模型转化。此外，依托 onnx 当前完善的生态，大部分利用主流深度学习框架（如 PyTorch 与 Caffe 等）开发的模型也都可以先转换为 onnx 模型间接地完成 bmodel 转化。



精度与效率并存

TPU-MLIR 支持 INT8 对称和非对称量化，在大幅提升性能的同时又结合原始开发企业的 Calibration 与 Tune 等技术保证了模型的高精度。不仅如此，TPU-MLIR 中还运用了大量图优化和算子切分优化技术，以保证模型的高效运行。



完善文档支持

一个好的开源项目必须配套完善的用户文档，才能让用户以最小的代价入门，一起参与进来共同贡献，同时如果配合完善的用户文档，贡献者也可以自己探索一些不常用的模块，最大限度的提高大家协作的效率。

03 生成式AI应用在RISC-V上的实践

以用为本 拥抱创新


通用AI助手

技术实现

核心架构为“LLM大脑+RAG知识库+工具调用”

客户端运行于PC端，包括用户页面、系统服务，负责与用户进行交互、语音识别、与云端交互、命令执行等

云端负责与LLM交互、进行推理决策，回答用户问题或者下发执行命令等，同时提供设备身份认证、token计费、Memory、RAG等功能。




03 生成式AI应用在RISC-V上的实践

■ 以用为本 拥抱创新

通用AI助手

RISC-V AI 系统助手

- 智能系统设置
- 智能文件搜索
- 智能问答
- 代码补全（vscode插件）
- 语音操控
- 设备鉴权



通用AI助手

自定义工具（文件查询）

方法定义：query_files(conditions) ，
conditions参数是一个字典，这个字典包含了各种文件查询条件，其可能的键值对如下：

方法描述：根据给定的条件查询本地PC 上的文件。它通过调用系统指令（如find、grep等）来实现文件/文件内容的按条件查询。

模型返回：

```
{
  "message": "查找在/home/userA目录下，大于5MB且文件内容包含"data"的最近5天访问的文件",
  "conditions": {
    "filename": "xxxx",
    "filetype": "xxxx",
    "filesize": {"min": 5, "max": 10, "unit": "MB"}, //只搜某个大小的则min与max相同，unit可能为"MB" "KB"等
    "create_time": {"begin": "yyyy-mm-dd", "end": "yyyy-mm-dd"}, //只搜某一天的则begin与end相同，不确定的字段会置为0，如5月20日为0000-05-20，需要前端补全下
    "modify_time": {"begin": "yyyy-mm-dd", "end": "yyyy-mm-dd"},
    "access_time": {"begin": "yyyy-mm-dd", "end": "yyyy-mm-dd"},
    "storage_location": "xxxx",
    "file_permission": "xxxx",
    "content": "xxxx"
  }
}
```

04 未来展望



持续提高性能

芯片型号	玄铁C930	进迭时空K1	超睿科技UR-DP1000	奕斯伟EIC7702X	香山“昆明湖”
制程工艺	未明确（推测7nm）	22nm	12nm	12nm	7nm
核心数量	支持16核至64核配置	8核	8核（双四核簇）	8核（双四核簇）	单核设计，支持多核扩展
主频	3GHz	2.0GHz	2.0~2.3GHz	推测1.8GHz	3GHz
SPECint2006/GHz	15分/GHz	/	10.4分/GHz（整数）	/	15分/GHz（优化后达47.63分）
AI算力	8 TOPS（Matrix引擎）	2 TOPS（CPU融合算力）	未标注	2个NPU 共40TOPS 算力	集成矢量和AI加速模块
扩展指令集	512位RVV1.0 + Matrix扩展	256位RVV1.0 + RVA22 Profile	RV64GCBHX + RVH1.0虚拟化	512位RVV1.0 + RVA23功能集	矢量扩展 + 虚拟机管理程序扩展
应用场景	服务器、自动驾驶、边缘计算	智慧平板，桌面PC，边缘计算	桌面PC，边缘计算	数据中心、HPC、AI推理	数据中心，服务器
能效比	通用与AI算力原生结合，能耗降低30%	典型功耗3.5W，算力能效超A55 1.2倍	TDP 30W	/	性能对标Arm Neoverse N2

持续完善生态,培养更多人才

- 软件生态尚不完善，需要更多人参与进来。
- 科研机构与企业需要合力来完善生态
- 加入RISC-Vers社区，共建开源生态。

持续拥抱AI，打造标杆应用案例

- RISC-V 在AI领域很有前景，但依然存在一些发展瓶颈。缺少一个标杆应用案例。

RISC-Vers 社区

- RISC-Vers 社区是联合 RISC-V 工委及一众优秀的生态合作单位联合发起，秉承开源开放精神，鼓励自由贡献和协作，共同构建 RISC-V 原生基础软件栈，推动 RISC-V 的技术发展和产业应用。
- 网址：<https://risc-verse.cn/>



04 未来展望

■ 以用为本 拥抱创新

社区生态&参与



Thanks