

稀疏化：通向更高效大模型的关键

王朝晓

统信软件大语言模型研发工程师

Content

目录

01

大模型稀疏化概述

02

稀疏化的挑战与
优势

03

前馈神经网络层
稀疏化

04

注意力层稀疏化

05

激活值稀疏化

06

未来与展望

01


大模型稀疏化概述



01 大模型稀疏化概述

以用为本 拥抱创新

涌现能力+规模定律
使得大模型近几年发展迅猛，在多项任务，并达到SoTa（最先进水平），背后原理仍是仿大脑神经网络的矩阵运算。




2023年起，大模型能力密度平均每**3.3**个月翻一倍

<https://arxiv.org/pdf/2412.04315>

01 大模型稀疏化概述

■ 以用为本 拥抱创新

当前主流大模型按照激活及存储情况可以分为密集模型与稀疏模型两个大类，密集模型如Llama系列、Phi系列等，稀疏模型如MOE架构系列模型。



- 人脑神经元数量 ≈ 2000 亿
- 单次推理能耗 $\leq 15W$
- 单次推理时长 $\approx 100ms$
- 单次推理激活神经元比例 $\leq 5\%$
- 知识分区域存储
- GPT3参数规模 = 1700亿
- 单次推理能耗 $\approx 400W$
- 单次推理时长 $\approx 2000ms$
- 单次推理激活神经元比例 = 100%



GPT-3

<https://arxiv.org/pdf/2005.14165>

https://www.researchgate.net/publication/224005436_The_economy_of_brain_network_organization

大模型稀疏化概述

以用为本 拥抱创新

神经网络本身是大脑神经元的启发式算法，那么大模型作为一种深度神经网络，其推理时激活的权重比例是否也可控制在5%以内？不同类型知识是否也分区域存储？






Figure 2: CDF of the ratio of activated neurons for each input with different models on three datasets.



在多项任务上仅需激活前馈网络中少量神经元即可达到任务性能不下降。




同一前馈神经网络层中神经元存在功能分化。

<https://arxiv.org/pdf/2409.02877>
<https://arxiv.org/pdf/2110.01786>

大模型稀疏化概述


以用为本 拥抱创新

模型压缩（量化等）、稀疏化(剪枝等)方案已成为端侧部署的必备策略。



大模型不同任务在推理时会存在 $\leq 1\%$ 的重要性权重，而这些重要性权重使得模型压缩或稀疏化时需要根据任务动态感知。

<https://arxiv.org/pdf/2308.06767>
<https://arxiv.org/pdf/2211.10438>



近年来关于模型压缩、剪枝研究的热度持续上涨。

模型稀疏化是一个比较大的课题，这里仅对当前关注度较高的方案进行交流分享。

02

稀疏化的挑战与优势



02 稀疏化的挑战与优势

■ 以用为本 拥抱创新


GPT-o1、o3；DeepSeek-R1这类推理模型使得推理范式从“大”模型转为“长”模型，激增的长上下文对于推理效率以及KVCache存储空间管理带来了巨大挑战，模型稀疏化可同时解决上述问题！

稀疏化的挑战：

- 硬件适配性；
- 算子层适配性；
- 模型表现可能有损；
- 稀疏方案多样，动态稀疏、静态稀疏、训练时稀疏、训练后稀疏的效果不同；
-

稀疏化的优势：

- 训练及推理效率提升；
- 存储空间降低；
- 可进行定制化异构推理方案；
- 提高大模型可解释性
-



https://github.com/deepseek-ai/DeepSeek-R1/blob/main/DeepSeek_R1.pdf

03


前馈神经网络层稀疏化



03 前馈神经网络层稀疏化

以用为本 拥抱创新

MOE (Mixture of Experts) —混合专家模型



- 前馈神经网络层在不同领域输入下会存在神经元分化；
- 前馈神经网络层中神经元具有功能特异性，相似功能神经元被激活；
- 前馈神经网络层20%神经元即可实现98%全部神经元的正确率；

03 前馈神经网络层稀疏化


以用为本 拥抱创新

DeepSeek-V3/R1

激活专家数	总专家数	专家比例
1+8	256+1	3.50%
激活权重	总权重	激活比例
37B	670B	5.52%

- MOE层可以大致分为两个部分：路由器（路由到top-K个专家）、n个专家FFN；
- 路由器又可以分为门控（softmax操作，选择不同专家的权重）以及选择器（选择Top-K个专家）；

<https://arxiv.org/pdf/2412.19437>



03 前馈神经网络层稀疏化

以用为本 拥抱创新

本地部署DeepSeek-R1

Prompt (500 tokens)	Dual socket Ktrans (6 experts)	Dual socket Ktrans (8 experts)	Single socket Ktrans (6 experts)	Single socket Ktrans (8 experts)	llama.cpp (8 experts)
Prefill token/s	97.32	82.94	65.14	54.21	10.31
Decode token/s	13.69	12.208	10.303	8.73	4.51

- Model: DeepseekV3-q4km (int4)-约400GB
- GPU: 4090D 24G VRAM
- Single socket: 382G DRAM, at least 14GB VRAM
- Dual socket: 1T DRAM, at least 14GB VRAM
- MOE稀疏化可以定制化异构推理；
- 仅加载激活的专家；
- 软硬件结合推理，工程集成优化；

<https://github.com/kvcache-ai/ktransformers>

04

注意力层稀疏化



04 注意力层稀疏化


以用为本 拥抱创新

为什么注意力层可以稀疏化？


KV Cache计算，以Qwen QwQ-32B为例，半精度存储：

Sequence Length	KV Cache Memory (GB)
1000	0.24
5000	1.22
10000	2.44
20000	4.88
30000	7.32
40000	9.77


经过实验发现
query与kv之间
相似性呈现分块
特性（空间聚集
性）



NSA



(a) Attention patterns



(b) Attention is spatial clustering

Minference


<https://arxiv.org/pdf/2502.11089>

<https://arxiv.org/pdf/2407.02490>

04 注意力层稀疏化

以用为本 拥抱创新

Native Sparse Attention: Hardware-Aligned and Natively Trainable Sparse Attention




- 训练时稀疏化，补齐推理稀疏gap；
- 粗/细粒度、全局/局部注意力组合稀疏；
- 定制化Kernel算子；

- 全局压缩：KV切块压缩；
- 动态选择：选择与上下文相关的KV；
- 局部注意力：窗口滑动注意力；

04 注意力层稀疏化

以用为本 拥抱创新



- NSA注意力稀疏化方案较标注注意力速度提升明显。
- NSA注意力稀疏化方案较其他注意力稀疏方案评测占优。

Model	SQA			MQA				Synthetic		Code	Avg.
	MFQA-en	MFQA-zh	Qasper	HPQ	2Wiki	GovRpt	Dur	PassR-en	PassR-zh	LCC	
H2O	0.428	0.429	0.308	0.112	0.101	0.231	0.208	0.704	0.421	0.092	0.303
InfLLM	0.474	0.517	0.356	0.306	0.250	0.277	0.257	0.766	0.486	0.143	0.383
Quest	0.495	0.561	0.365	0.295	0.245	0.293	0.257	0.792	0.478	0.135	0.392
Exact-Top	0.502	0.605	0.397	0.321	0.288	0.316	0.291	0.810	0.548	0.156	0.423
Full Attn	0.512	0.623	0.409	0.350	0.305	0.324	0.294	0.830	0.560	0.163	0.437
NSA	<u>0.503</u>	0.624	0.432	0.437	0.356	0.307	0.341	0.905	<u>0.550</u>	0.232	0.469

05



激活值稀疏化




05 激活值稀疏化

以用为本 拥抱创新

- 激活函数使得模型中间激活值存在天然稀疏性；
- 激活稀疏性阈值设置；
- 静态稀疏 vs 动态稀疏
- 稀疏阈值设置后训练如何反向求导；




ReLU




SiLU

05 激活值稀疏化


以用为本 拥抱创新





(a) Contextual sparsity in Attention Head




(b) Contextual sparsity in MLP Block



Deja Vu通过训练一个预测器，来异步预测激活的神经元从而实现加速推理及计算。




(a) Language Modeling



(b) Zero-Shot(Left). Five-Shot(Right)


06 激活值稀疏化

以用为本 拥抱创新



PowerInfer异构推理模式方案

- 使用提前训练的预测器区分hot和cold神经元;
- Prefill和Decode分离, hot和cold神经元分离;
- CPU和NPU异构推理;
- 工程调优, CPU调度优化、IO优化;



<https://arxiv.org/pdf/2406.06282>

<https://github.com/SJTU-IPADS/PowerInfer.git>

06

未来与展望



稀疏架构的发展方向是什么？

异构推理效率


在异构系统中实施稀疏性可以提高推理效率。

创新模块

开发统一的活跃神经元预测模块可以推动创新。

长期记忆和遗忘

稀疏性使模型具备有效的长期记忆和短期遗忘能力。



替代注意力机制

稀疏注意力到线性机制的过渡可能会改变传统方法。

流式数据处理

稀疏性是处理无限长流式数据的关键。

端侧设备优化

将稀疏架构调整为端侧设备可以提高性能和适应性。

Thanks For Watching

深度科技社区



微信公众号

